

絶対に飽きない生物コラム 第十四話＞ ～分子系統樹とハーディーワインベルグ～

さて、絶対に飽きない生物コラム第十四話です。今回は、教科書では生物の進化として扱われる部分の、主として分子系統樹作成の数理生物学的な議論を少し書きます。若干難易度が高くなる予感がしていますが、頑張ってください。

* * *

分子系統樹作成の原理を説明しなさいということですから、説明しますが、その前に、オーソログの話だけします。急に意味不明なカタカナが登場して焦った人もいるかもしれませんが、大事な用語なので知っておくといいです。オーソログは、種分岐の前に全く同じ遺伝子だった遺伝子を指します。通常機能が一緒です。これと並んで登場するのがパラログです。パラログは、遺伝子重複によってできた類似遺伝子のことです。この例えが伝わるかわかりませんが、オーソログが相同器官、パラログが相似器官のような感じです。主としてオーソログをたどることで、系統解析が進められることになります。オーソログについてはゲノムが解読された生物のオーソログ関係が簡単に調べられるサイトがあります

(<http://www.ncbi.nlm.nih.gov/COG/>)。

そのほか、分子系統樹作成の材料となるものを先に説明してしまいます。多重アラインメントというものです。これは、大学入試で系統樹を作るという問題が出題される際にくっついてくるあの表のことです。どの生物種間でどんなアミノ酸配列・DNA配列の変化があるのかを示した表です。しかし、この多重アラインメントを作るのも実は一苦勞です。なぜなら、最初に配列が入力された状態ではどれとどれが対応するのかは不明、残基同士を対応させるのはかなり難しいからです。

＜多重アラインメント作成法＞

一つ目の作り方が、累進法というものです。これは、ペアワイズアラインメントの作成から始めて、マルチプルアラインメントを得るものです。具体的には、入力された配列の全通りの比較を行い、それぞれの場合の距離の行列、それぞれの場合の系統樹を計算します。しかし途中段階のアラインメントのエラーを取り除けないため最終的な精度は落ちることが多いです。

二つ目の方法が反復改善法です。この場合は、累進法などで得られたアラインメントを2つに分割し、それぞれのグループ内でアラインメントを計算します。距離行列の絶対値によるアラインメントスコアを各グループ分け・各系統関係の場合について計算し、アラインメントスコアが向上した際には新しいアラインメントの分割を試し、アラインメントスコアが上がらなくなるまで繰り返します。累進法より計算量は多いものの、高精度なアラインメントが得られるわけです。

ここまでが根本的な進化系統樹の作成方法です。もはや情報ですね。これを入試問題で簡単に解ける皆さんはもはや人間コンピュータです。


次に進化距離を計算します。

一般に、共通の祖先に由来する2つの配列について、それらが分岐してから現在に至るまでに蓄積した置換の数を置換数といい、置換数を座位数で割ったものを進化距離と呼びます。なお、時々見る相違度という指標はまた別の指標です。これは、一致しない座位数を比較する座位数で割ったものですが、なぜ進化距離と同じでないのかわかりますか？

相違度は多重置換（同一箇所への複数回の置換）や復帰置換（祖先型に戻るような置換）を見逃してしまうからです。要注意。

それではやっと本題に入れます。系統樹です。系統樹は、一般には皆さんがあまり目にしない、無根系統樹がほとんどです。なぜなら、一般のアラインメントでは類縁関係は遡れますが、どれを基準にするかによって、分子系統樹の形が大きく変化するからです。こうして基準として設ける生き物を外群と呼びます。こうすれば、外群の生き物に対する距離で系統樹が組み立てられますね。一般のコンピュータ解析では、まず無根系統樹を作製し、これに外群を加えます。

問題です。4種類の生物種がいる際にとりうる無根系統樹は何通りですか？



A.3 通りです。

問題です。10種類の生物種がいる際にとりうる無根系統樹は何通りですか？

A.2027025 通りです。

爆発的に増加します。場合の数の問題になりますが、 k 種類の生物種が存在する場合に取りうる無根系統樹の数は次の式で表されます。


$$N_{unrooted} = \prod_{i=3}^n (2i-5) = \frac{(2n-5)!}{2^{n-3}(n-3)!}$$

恐ろしい増加ぶりを示すことは、皆さんの極限の感覚からもよくわかることでしょう。導出は自分でやってみてください。

ここから、クラスタリング法と呼ばれる、系統樹を調べる手法をいくつか紹介します。


<UPGMA(平均距離法、またの名を非加重結合法)>

先ほど説明した進化距離をもとにした方法です。この場合、進化速度の一定性を仮定し、有根系統樹を得ます。皆さんが普通に問題を解くとき、何気なく使うやつです。これとこれのアミノ酸配列の差が8個だから、別れてからそれぞれ4個ずつ変異したね、というやつ。簡単でもいいんですけど、進化速度が系統間で異なる場合には誤った推定をしがちである、という問題があります。



<最節約法>

入試で一番見る方法です。考えられるすべての系統樹の中から、形質の変化の数が最も少ないものを選択する方法です。配列の座位ごとに必要な変異の数のうち、総変異数が最小の無根系統樹を採用します。しかし、同じ配列に2度以上の置換が起きる多重置換の場合には推定を誤りやすく、配列の違いが大きいと可能性がとてつもなく広がるので、配列が比較的類似したものに限定すべきです。なお、最節約法の説明文がどんな感じかにもよりますが、最節約法においては進化速度が一定であることは仮定されていません。受験生がどう考えるべきかは不明ですが、使わなくて済むなら使わない方が、、、いいのかもしれません。



<近隣結合法>

系統樹を段階的に構成していくアルゴリズムによるクラスタ解析法です。多くの段階で、すべての枝の長さの合計が最小となるトポロジーを望ましいとしています。この場合、はじめに放射状の系統樹を仮定し、特定の配列が2本の枝でつながる近隣関係にあると仮定したうえで系統樹全体に必要な枝の長さを計算します。このとき、別の配列がうまく説明できないとき、違う配列同士が近縁関係にあるとしてみても、うまく説明がつかを確認します。この場合は、系統ごとの進化速度が等しいことを仮定しなくて済むほか、他の系統解析法では計算能力的に不可能な量のデータセットも扱えるという利点があります。ATGCの入れ替わる確率のモデル

	A	G	C	T
A	-	α	β	β
G	α	-	β	β
C	β	β	-	α
T	β	β	α	-

は様々であり、木村資生が提唱したK80では、左図のようにプリン間 (AとG)・ピリミジン間 (CとT) の転移 (トランジション) はそれ以外の置換であるトランスバージョンに比べて起こりやすいことが反映されています。

<最尤法>

想定れる樹形ごとにおいて現在の配列が得られる条件付き確率（尤度）を求め、最も尤度の高い樹形を採用する方法です。計算量が多く、条件付き確率が絡むため、高校生が挑むにはちょっと大変です。

* * *

長くなりましたが、分子系統樹作成の基本原理を書きました。実際には大学の数理生物学系の授業で、プログラミングを駆使しながら計算することになります。こういうことを知ってむしろ入試が解きにくくなった筆者ほどに深ぼらない方がいいかもしれませんが、数学が好きな人にとってはかなり面白い分野です。それではまた。